

Prédiction de l'Âge Biologique à partir des Données de Méthylation de l'ADN

Auteurs : Lambert Ndiaye, Ass Ndiaye et Abakar Oumar Abakar

Support technique : Puce Illumina 850K

Échantillons : ~400 prélèvements sanguins

Sites CpG : ~894 000

Répartition : 80 % entraînement / 10 % validation / 10 % test

Modèles explorés : PLS · Elastic Net · XGBoost · Stacking · Horloge de Zhang · DNN (AltumAge)

Sommaire

1. Introduction

2. Contexte scientifique

- 2.1 La méthylation de l'ADN : définition, valeurs β , rôle dans la régulation génique et le vieillissement.
- 2.2 Pourquoi prédire l'âge biologique ? : applications en santé préventive, médecine personnalisée, recherche sur la longévité, etc.

3. Objectifs du projet

4. Présentation des données

5. Analyse des données

- 5.1 Aperçu de la matrice après prétraitement : 400 individus, 1004 colonnes (dont 1000 CpG).
- 5.2 Influence des variables démographiques : l'ethnicité et le sexe n'ont pas d'impact significatif sur la prédiction.

6. Prétraitement des données

- 6.1 Transposition de la matrice
- 6.2 Nettoyage et exclusion
- 6.3 Filtrage qualité
- 6.4 Gestion des valeurs manquantes (imputation par la médiane)
- 6.5 Division des données (80/10/10)
- 6.6 Standardisation
- 6.7 Sélection des CpG par corrélation de Pearson (réduction à 5 162 CpG)

7. Méthodes utilisées

- 7.1 PLS Regression
- 7.2 Elastic Net
- 7.3 XGBoost
- 7.4 Random Forest
- 7.5 Stacking
- 7.6 Gaussian Process

8. Horloge épigénétique de Zhang — modèle pré-entraîné

- 8.1 Présentation du modèle (10 CpG, MAE ~2 ans)
- 8.2 Application sur notre cohorte (seulement 7/10 CpG disponibles)
- 8.3 Fine-tuning du modèle (MAE finale 3,61 ans)

9. Deep Neural Network (DNN) — AltumAge

- 9.1 Principe du deep learning pour la méthylation
- 9.2 AltumAge : modèle pré-entraîné sur 142 datasets
- 9.3 Fine-tuning sur notre cohorte (MAE = 4,92 ans)
- 9.4 Limites du DNN avec peu de données

10. Résultats obtenus

- 10.1 Tableau récapitulatif des performances (Stacking : 2,40 ans ; PLS : 2,50 ans ; etc.)
- 10.2 Analyse détaillée des résultats par modèle

11. Contraintes et limites

12. Perspectives d'amélioration

13. Conclusion

14. Références bibliographiques

1. Introduction

Le vieillissement humain ne se réduit pas au simple écoulement du temps. Deux individus d'âge chronologique identique peuvent afficher des états physiologiques très différents, sous l'influence de leur génétique, de leur mode de vie, de leur alimentation, de leur niveau de stress ou encore de pathologies chroniques. Cette dissociation entre l'âge calendaire et l'état biologique réel a conduit les chercheurs à développer la notion d'**âge biologique**, reflet plus fidèle du vieillissement de l'organisme.

Parmi les biomarqueurs disponibles pour estimer cet âge biologique, la **méthylation de l'ADN** s'impose comme la plus performante et la plus reproductible. Les travaux pionniers d'Horvath (2013) ont montré qu'une combinaison de sites CpG spécifiques permet de prédire l'âge biologique avec une erreur inférieure à quatre ans sur de larges cohortes, donnant naissance au concept d'**horloge épigénétique**.

L'ambition de ce projet est de développer, comparer et affiner plusieurs modèles d'intelligence artificielle capables d'estimer l'âge biologique à partir de profils de méthylation ADN issus d'une puce Illumina 850K. Nous couvrons l'intégralité du processus : de la préparation des données brutes à la comparaison de modèles avancés, en passant par l'exploitation d'horloges pré-entraînées et le fine-tuning de réseaux de neurones profonds.

2. Contexte scientifique

2.1 La méthylation de l'ADN

La méthylation de l'ADN correspond à l'ajout covalent d'un groupement méthyle ($-CH_3$) sur le carbone en position 5 d'une cytosine, presque exclusivement au sein des dinucléotides CpG. Le niveau de méthylation d'un site CpG est exprimé par une **valeur β** comprise entre 0 (non méthylé) et 1 (entièrement méthylé).

Cette modification épigénétique joue un rôle clé dans la régulation de l'expression des gènes : la méthylation d'un promoteur est généralement associée à son silence. Avec l'âge, certains sites CpG s'hyperméthylent progressivement, d'autres s'hypométhylent, de manière systématique et reproductible. Ces changements reflètent l'accumulation des effets du vieillissement cellulaire, du stress oxydatif et des influences environnementales.

C'est cette régularité interindividuelle qui permet d'utiliser la méthylation pour construire des horloges biologiques : en modélisant la relation entre les niveaux de méthylation et l'âge chronologique, on obtient un estimateur de l'âge biologique pour tout nouvel individu.

2.2 Pourquoi prédire l'âge biologique ?

Les applications cliniques et scientifiques sont nombreuses et en pleine expansion :

- **Santé préventive** : détecter un vieillissement accéléré avant l'apparition des symptômes.
- **Médecine personnalisée** : adapter les traitements à l'état biologique réel du patient.
- **Recherche sur les maladies liées à l'âge** : cancers, maladie d'Alzheimer, maladies cardiovasculaires.
- **Recherche sur la longévité** : évaluer l'impact d'interventions (alimentation, exercice, médicaments).
- **Médecine légale** : estimer l'âge d'une personne à partir d'un échantillon biologique.

3. Objectifs du projet

Ce projet poursuit plusieurs objectifs complémentaires, couvrant l'ensemble du pipeline de la data science appliquée à la biologie :

1. Analyser et comprendre la structure d'un jeu de données réel de méthylation ADN en haute dimension.
2. Nettoyer, filtrer et structurer les données rigoureusement pour éviter tout biais.
3. Sélectionner les CpG les plus informatifs par des méthodes statistiques supervisées.
4. Développer et comparer plusieurs modèles statistiques et d'apprentissage automatique.
5. Utiliser des horloges épigénétiques pré-entraînées (Zhang) et les adapter à notre cohorte.
6. Explorer le deep learning (DNN) pour capturer des relations non linéaires.
7. Optimiser les performances par fine-tuning et calibration.
8. Analyser et interpréter les limites biologiques et statistiques du jeu de données.

4. Présentation des données

Le jeu de données est issu de profils de méthylation ADN mesurés sur une puce **Illumina MethylationEPIC 850K**, la plateforme de référence actuelle en épigénomique.

Caractéristique	Valeur	Remarque
Nombre d'échantillons	~400 individus	Après filtrage qualité
Sites CpG bruts	894 006	Couverture quasi-complète du méthylome
Variable cible	Âge (années, continu)	Min ~20 ans, Max ~80 ans
Type de tissu	Sang entier	Tissu de référence en épigénétique
Plateforme	Illumina EPIC 850K	Valeurs β entre 0 et 1
Variables exclues	Sexe, ethnicité	Métadonnées non CpG
Format de stockage	Parquet	Optimisé pour grandes matrices

Le contexte statistique est celui du **p >> n** : le nombre de variables (894 000 CpG) dépasse de très loin le nombre d'observations (~400 individus). Ce déséquilibre impose des stratégies spécifiques de réduction de dimensionnalité et de régularisation pour éviter le sur-apprentissage.

5. Analyse des données

5.1 Aperçu de la matrice après prétraitement

Après transposition, filtrage qualité et imputation, le jeu de données final comprend :

- **400 échantillons** (individus)
- **1004 colonnes** :
 - Sample_description : identifiant unique
 - female : sexe (booléen)
 - ethnicity : groupe ethnique (catégoriel)

- age : variable cible (continue)
- 1000 sites CpG (valeurs β continues entre 0 et 1)

Nous sommes donc en présence d'un problème de **régression supervisée en grande dimension**.

5.2 Influence des variables démographiques

Ethnicité

- **Visualisation** : un boxplot de l'âge par groupe ethnique ne montre aucune différence marquée.




Figure 1:

- **Test ANOVA** : p-value = 0,7786 → aucune différence statistiquement significative.
- **Modélisation** (Random Forest, validation croisée 3 folds) :
 - Sans ethnicity : $R^2 = 0,6488$
 - Avec ethnicity : $R^2 = 0,6454$
- **Conclusion** : l'ajout de l'ethnicité n'améliore pas la prédiction.

Sexe

- **Test t de Student** : p-value = 0,0582 (proche du seuil)
- **Moyenne d'âge** : hommes 55,1 ans ; femmes 51,1 ans



p-value du test t : 0.0582
Moyenne hommes : 55.11
Moyenne femmes : 51.08

Figure 2 :

- **Corrélation sexe/âge** : -0,0948 (très faible)
- **Modélisation** :
 - Sans female : $R^2 = 0,6461$
 - Avec female : $R^2 = 0,6486$ (gain marginal)
- **Importance des features** : quasi nulle (0,00001)
- **Analyse SHAP** : impact moyen proche de zéro
- **Conclusion** : le sexe n'a pas d'impact significatif.

6. Prétraitement des données

Pour commencer, nous avons assemblé les différentes sources de données par une jointure. L'objectif était de récupérer, pour chaque prélèvement, le nom des CpG, l'identifiant de l'échantillon, ainsi que des caractéristiques individuelles comme le sexe, l'ethnicité et l'âge. Nous avons ensuite organisé ces informations dans une

matrice où chaque ligne représente un CpG (ainsi que le sexe et l'ethnicité) et chaque colonne correspond à un échantillon.

6.1 Transposition de la matrice

Les données brutes (CpG en lignes, échantillons en colonnes) ont été transposées pour respecter la convention : lignes = observations, colonnes = variables.

6.2 Nettoyage et exclusion

Les variables de métadonnées (sexe, ethnicité) ont été retirées. La colonne age a été extraite comme variable cible.

6.3 Filtrage qualité

- **Échantillons** : exclus si >10 % de valeurs manquantes.
- **CpG** : exclus si >0,1 % de valeurs manquantes → 782 711 CpG conservés.

6.4 Gestion des valeurs manquantes

Imputation par la **médiane** de chaque CpG (robuste aux outliers), calculée uniquement sur le jeu d'entraînement.

Principe fondamental : toute transformation (médiane, écart-type, corrélation) est apprise sur l'entraînement puis appliquée à la validation et au test, pour éviter toute fuite d'information.

6.5 Division des données

- **Train** : 80 % (~312 individus)
- **Validation** : 10 % (~39 individus)
- **Test** : 10 % (~39 individus)

6.6 Standardisation

Standardisation (moyenne = 0, écart-type = 1) de tous les CpG, ajustée sur le train uniquement.

6.7 Sélection des CpG par corrélation de Pearson

Seuil optimal $|r| \geq 0,53$, limité à 7 000 CpG maximum. La dimension passe de 782 711 à **5 162 variables** (réduction de 97,7 %). Les CpG les plus corrélés à l'âge incluent cg16867657 ($r = 0,924$), cg26947034 ($r = 0,868$), cg10501210 ($r = 0,856$).

7. Méthodes utilisées


7.1 PLS Regression (Partial Least Squares)

La régression PLS est particulièrement bien adaptée au contexte $p \gg n$. Contrairement à la régression ordinaire qui échoue quand $p > n$, la PLS projette simultanément les matrices X et y dans un espace latent de dimension réduite en **maximisant la covariance** entre les deux. Chaque composante latente est une combinaison linéaire de tous les CpGs qui capture à la fois la variance dans X et la corrélation avec l'âge y . Le nombre de composantes N est un hyperparamètre optimisé par validation croisée à 5 folds.




7.2 Elastic Net

L'Elastic Net est une régression linéaire régularisée combinant deux pénalités complémentaires. La pénalité **L1 (Lasso)** met certains coefficients exactement à zéro, réalisant ainsi une sélection automatique de variables. La pénalité **L2 (Ridge)** pénalise les gros coefficients sans les annuler, assurant la stabilité numérique quand des CpGs sont corrélés entre eux. Le ratio $l1/l2$ et le paramètre de régularisation global α sont déterminés par cross-validation (ElasticNetCV).



7.3 XGBoost

L'eXtreme Gradient Boosting construit une séquence d'arbres de décision, chaque nouvel arbre corrigeant les erreurs du précédent. Sa capacité à capturer des **interactions non linéaires** entre CpGs en fait un candidat naturel pour ce type de données. La configuration utilisée emploie 1 000 arbres avec un taux d'apprentissage faible (0,01) pour garantir la convergence progressive.




7.4 Random Forest

La forêt aléatoire construit 1 000 arbres indépendants, chacun entraîné sur un sous-ensemble aléatoire des données et des features. La prédiction finale est la moyenne des 1 000 arbres. Ce mécanisme de **bagging** réduit la variance. La Random Forest fournit également des scores d'importance des features, permettant d'identifier les CpGs les plus prédictifs.


7.5 Stacking

Le stacking combine les prédictions de plusieurs modèles de base via un **méta-modèle** appris sur les sorties des modèles individuels. Plutôt que de moyenner simplement les prédictions, le méta-modèle apprend quelle combinaison de modèles est optimale. Dans ce projet, les poids ont été optimisés numériquement (SLSQP) sur le validation set pour minimiser la MAE.



7.6 Gaussian Process

Le Processus Gaussien est un modèle probabiliste non-paramétrique qui fournit non seulement une prédiction ponctuelle mais aussi une **estimation de l'incertitude** associée à chaque prédiction. Un kernel Matérn ($\nu=1,5$) combiné à un WhiteKernel a été utilisé, après réduction préalable par PCA (97% de variance expliquée) pour rendre le calcul tractable.



8. Horloge épigénétique de Zhang — modèle pré-entraîné

L'horloge de Zhang (Zhang et al., 2023 — Cell Reports Methods) est l'une des horloges épigénétiques les plus précises pour le sang entier. Contrairement aux approches classiques qui utilisent des centaines de CpGs, Zhang a identifié un ensemble de seulement **10 sites CpG** suffisants pour prédire l'âge chronologique avec une MAE d'environ **2 ans sur sang entier** dans des cohortes larges.

Le modèle est une **régression Elastic Net** entraînée sur une cohorte composite de plus de **11 910 méthylomes sanguins** issus de 19 datasets publics disponibles sur GEO (Gene Expression Omnibus), couvrant des âges de 0 à 103 ans. Cette très large base d'entraînement explique la robustesse et la généralisation du modèle à de nouvelles cohortes.

Données d'entraînement de Zhang :

- 11 910 méthylomes sanguins (Illumina 450K et EPIC)
- 19 cohortes publiques (GEO), âges 0–103 ans
- Seulement 10 CpGs sélectionnés — MAE publiée ~2 ans sur sang
- Modèle : Elastic Net avec coefficients fixes, applicable sans réentraînement

8.1 Application sur notre cohorte

Seuls **7 des 10 CpG** sont disponibles. Impact sur les performances :

Approche	CpG utilisés	MAE (ans)
Coefficients officiels directs	7/10	14,83
RidgeCV recalibré sur 7 CpG	7/10	6,46
Residual learning (base + 500 CpG supplémentaires)	7 + 500	3,61

Le fine-tuning permet d'améliorer la MAE, mais l'absence des trois CpG reste pénalisante.

9. Deep Neural Network (DNN) — AltumAge

AltumAge (de Lima Camillo et al., 2022) est une horloge épigénétique basée sur un réseau de neurones profond, entraînée sur **142 datasets publics** (plusieurs dizaines de milliers d'échantillons) et **20 318 CpG** communs à toutes les puces Illumina.

Architecture

- Input (20 318 CpG)
- Dense (512, ReLU) + Dropout (0,3)
- Dense (256, ReLU) + Dropout (0,3)
- Dense (128, ReLU) + Dropout (0,2)
- Output (1 neurone)

Fine-tuning sur notre cohorte

- Seule la dernière couche est réentraînée (transfer learning).
- Learning rate = 1×10^{-4} , batch size = 16, early stopping.
- **MAE obtenue : 4,92 ans.**

Limite

Avec seulement ~300 individus en entraînement, le DNN ne peut exprimer tout son potentiel. Les modèles linéaires (PLS, Elastic Net) sont plus robustes en faible effectif.

10. Résultats obtenus

Modèle	MAE (ans)	R ²	Commentaire
Stacking	2,39	~0,97	Meilleure performance globale
PLS (N=10)	2,50	~0,97	Meilleur modèle individuel
Elastic Net + PLS calibré	2,71	~0,96	Sélection automatique de CpG
XGBoost	3,20	~0,95	Capture de non-linéarités
Zhang fine-tuné (7/10 CpG)	3,61	~0,95	Limitée par CpG manquants
Random Forest	>3,5	~0,94	Moins adapté au $p \gg n$

Analyse

- **PLS** atteint 2,50 ans de MAE, en ligne avec l'état de l'art.
- **Elastic Net** offre une interprétabilité intéressante.
- **Stacking** (2,40 ans) illustre la sagesse des foules : la combinaison réduit la variance des erreurs.
- **Zhang** est pénalisée par l'absence de trois CpG essentiels.

11. Contraintes et limites

- **Taille de cohorte** : ~400 individus, ce qui rend les estimations de MAE statistiquement instables.
- **CpG manquants de Zhang** : impossible d'exploiter pleinement ce modèle pré-entraîné.
- **Batch effect** : l'intégration de données externes nécessiterait une correction soigneuse (ComBat).

12. Perspectives d'amélioration

- **Intégration de cohortes GEO** : ajouter des données publiques (ex. GSE55763, ~650 individus) avec correction de batch.
- **Récupération des CpG Zhang manquants** : vérifier si possible depuis les données IDAT brutes.
- **Fine-tuning complet d'AltumAge** : avec >500 individus, adapter toutes les couches.
- **Analyse SHAP** : interpréter biologiquement les prédictions.
- **Approche multi-omics** : combiner méthylation, protéomique et transcriptomique.

13. Conclusion

Ce projet démontre qu'il est possible de prédire l'âge biologique avec précision à partir de données de méthylation ADN, même avec une cohorte modeste d'environ 400 individus. Le pipeline développé – filtrage rigoureux, sélection supervisée des CpG, comparaison systématique des modèles et optimisation par ensemble – constitue une base solide et reproductible.

La meilleure performance atteint **2,40 ans de MAE** (stacking), le PLS seul obtenant 2,50 ans. Ces résultats sont comparables à l'état de l'art pour des cohortes de cette taille. L'horloge de Zhang, bien qu'excellente sur le papier, est ici limitée par la couverture partielle des CpG.

Les perspectives d'amélioration – intégration de données externes, fine-tuning complet d'AltumAge – laissent espérer franchir la barre symbolique des **2 ans de MAE**, objectif fixé par le *Biomarkers of Aging Challenge 2024*.

14. Références bibliographiques

- Horvath S. *DNA methylation age of human tissues and cell types*. Genome Biology, 2013.
- Hannum G et al. *Genome-wide methylation profiles reveal aging rates*. Molecular Cell, 2013.
- Levine ME et al. *Epigenetic biomarker of aging: PhenoAge*. Aging, 2018.
- Lu AT et al. *GrimAge, a powerful predictor of mortality*. Aging, 2019.
- Zhang Q et al. *Improved precision of epigenetic clock estimates across tissues and its implication for biological ageing*. Nature Aging, 2023.

- de Lima Camillo LP, Lapierre LR, Singh R. *AltumAge: A pan-tissue DNA-methylation epigenetic clock based on deep learning*. npj Aging, 2022.
- Biomarkers of Aging Consortium. *An Open Competition for Biomarkers of Aging*. bioRxiv, 2024.
- Hastie T, Tibshirani R, Friedman J. *The Elements of Statistical Learning*. Springer, 2009.
- Géron A. *Hands-On Machine Learning with Scikit-Learn*. O'Reilly, 2022.
- Breiman L. *Random Forests*. Machine Learning, 2001.
- Chen T, Guestrin C. *XGBoost: A Scalable Tree Boosting System*. KDD, 2016.
- Varshavsky M et al. *Accurate age prediction from blood using a small set of DNA methylation sites*. Cell Reports Methods, 2023.